# Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

# Лабораторная работа №3 по дисциплине «Методы машинного обучения» на тему

«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Выполнил: студент группы

ИУ5-21М

Аунг Каунг Кхант


1. Цель лабораторной работы Изучить способы предварительной обработки данных для дальнейшего формирования моделей [1


```
In [0]: import numpy as np
         import pandas as pd
         import seaborn as sns
         import sklearn.impute
         import sklearn.preprocessing
          %matplotlib inline
sns.set(style="ticks")
          from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")
In [0]: pd.set_option("display.width", 70)
In [0]: data = pd.read_csv("googleplaystore.csv")
In [9]: data.head()
Out[9]:
                                                                                           Content
                                                                                                                     Last
                                                                                                                               Cu
            Арр
                        Category
                                           Rating Reviews
                                                            Size
                                                                  Installs
                                                                               Type Price
                                                                                                    Genres
                                                                                           Rating
                                                                                                                     Updated Ve
            Photo
            Editor &
            Candy
                                                                                                                     January
                        ART_AND_DESIGN 4.1
                                                   159
                                                            19M 10,000+
                                                                              Free 0
                                                                                           Everyone Art & Design
                                                                                                                               1.0
                                                                                                                     7, 2018
            Camera &
            Grid &
            ScrapBook
            Coloring
                                                                                                     Art &
                                                                                                                     January
          1 book
                                                   967
                       ART_AND_DESIGN 3.9
                                                            14M 500,000+
                                                                              Free 0
                                                                                           Everyone Design; Pretend
                                                                                                                               2.0
                                                                                                                     15. 2018
                                                                                                     Play
            moana
         Ш
```

```
In [10]: data.dtypes
Out[10]: App
                            object
                            object
         Category
         Rating
                           float64
         Reviews
                            int64
         Size
                            object
         Installs
                            object
         Type
                            object
         Price
                            object
         Content Rating
                            object
         Genres
                            object
         Last Updated
                           object
         Current Ver
                            object
         Android Ver
                           object
         dtype: object
In [11]: data.shape
Out[11]: (10841, 13)
```

### In [12]: data.isnull().sum() Out[12]: App Category 0 Rating 1474 Reviews 0 0 Size Installs 0 Туре Price Content Rating Genres 1 Last Updated 0 Current Ver 8 Android Ver 2 dtype: int64

## In [13]: sns.distplot(data["Rating"].fillna(0));






```
med_rat = med_imp.fit_transform(data[["Rating"]])
          sns.distplot(med_rat);
           3.0
           2.5
           2.0
           1.5
           1.0
           0.5
           0.0
In [16]: freq_imp = sklearn.impute.SimpleImputer(strategy="most_frequent")
           freq_rat = freq_imp.fit_transform(data[["Rating"]])
          sns.distplot(freq_rat);
           2.5
           2.0
           1.5
           1.0
           0.5
           0.0
In [20]: types = data["Type"].dropna().astype(str)
          types.value_counts()
Out[20]: Free
                  10040
         Paid
                   800
         Name: Type, dtype: int64
In [21]: le = sklearn.preprocessing.LabelEncoder()
          type_le = le.fit_transform(types)
          print(np.unique(type_le))
          le.inverse_transform(np.unique(type_le))
          [0 1]
Out[21]: array(['Free', 'Paid'], dtype=object)
In [23]: type_oh = pd.get_dummies(types)
          type_oh.head()
Out[23]:
            Free Paid
          0 1
                 0
          1 1
                 0
          2 1
                 0
          3 1
                 0
          4 1
                 0
```

In [15]: med\_imp = sklearn.impute.SimpleImputer(strategy="median")


```
In [24]: type_oh[type_oh["Paid"] == 1].head()

Out[24]: Free Paid
234 0 1
225 0 4
```

In [25]: mm = sklearn.preprocessing.MinMaxScaler()
 sns.distplot(mm.fit\_transform(data[["Rating"]]));



In [26]: ss = sklearn.preprocessing.StandardScaler()
 sns.distplot(ss.fit\_transform(data[["Rating"]]));



# Список литературы

- [1] Гапанюк Ю. Е. Лабораторная работа «Обработка пропусков в данных, кодиро- вание категориальных признаков, масштабирование данных» [Электронный ре- сурс] // GitHub. 2019. Режим доступа: https://github.com/ugapanyuk/ml\_ course/wiki/LAB\_MISSING (дата обращения: 05.04.2019).
- [2] Team The IPython Development. IPython 7.3.0 Documentation [Electronic resource] // Read the Docs. 2019. Access mode: https://ipython.readthedocs.io/en/ stable/ (online; accessed: 20.02.2019).
- [3] Waskom M. seaborn 0.9.0 documentation [Electronic resource] // PyData. 2018. Access mode: https://seaborn.pydata.org/ (online; accessed: 20.02.2019).
- [4] pandas 0.24.1 documentation [Electronic resource] // PyData. 2019. Access mode: http://pandas.pydata.org/pandas-docs/stable/ (online; accessed: 20.02.2019).
- [5] Gupta L. Google Play Store Apps [Electronic resource] // Kaggle. 2019. Access mode: https://www.kaggle.com/lava18/google-play-store-apps (online; accessed: 05.04.2019).